NoSQL

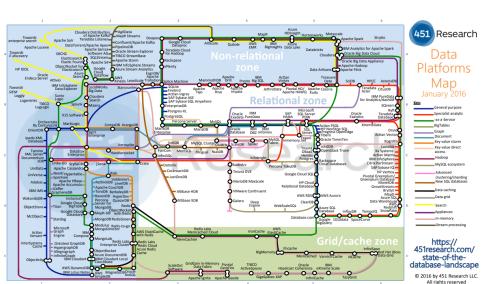
Document Based Databases

Gerardo Rossel



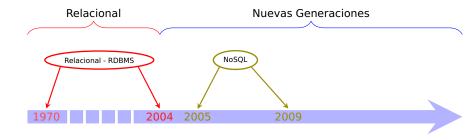
2024

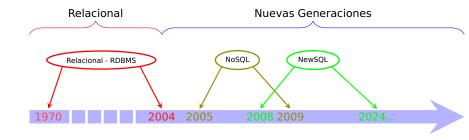
Introducción

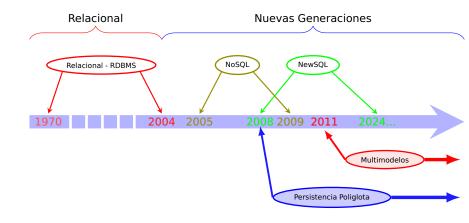


Relacional Nuevas Generaciones









¿Que se busca con NoSQL?

- Escalabilidad
- Disponibilidad, Replicación y consistencia eventual
- Alta performance en el acceso a datos
- ACID vs BASE.
- Sin esquema o esquema flexible



Definiciones

Origen

El nombre NoSQL tiene su origen en una reunión, para los investigadores y empresas que estaban trabajando en los nuevos modelos emergentes de bases de datos no relacionales, realizada en San Francisco en el año 2009 y organizada por Johan Oskarsson.

Definciones

HOW TO WRITE A CV







Leverage the NoSQL boom

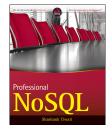
¿Que es NoSQL?

Eric Evans: Not Only SQL

Jon Oskarsson, 2009. Reunión en San Francisco

"NoSQLers came to share how they had overthrown the tyranny of slow, expensive relational databases in favor of more efficient and cheaper ways of managing data." Computerworld 2009

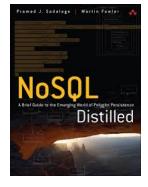
Definciones



Shashank Tiwari

NoSQL is used today as an umbrella term for all databases and data stores that don't follow the popular and well established RDBMS principles and often relate to large data sets accessed and manipulated on a Web scale. This means NoSOL is not a single product or even a single technology. It represents a class of products and a collection of diverse, and sometimes related, concepts about data storage and manipulation.

Definciones



Fowler -Sadalage

NoSQL is an accidental neologism. There is no prescriptive definition— all you can make is an observation of common characteristics.

Tipos de Bases No SQL

HOW TO WRITE A CV





Leverage the NoSQL boom

Tipos de Bases No SQL

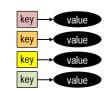
HOW TO WRITE A CV



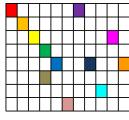




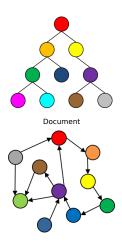
Leverage the NoSQL boom



Key-Vlue

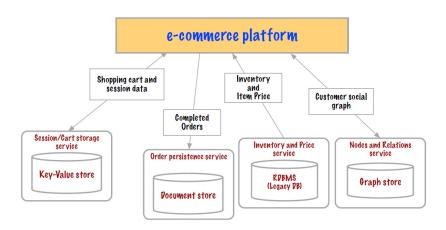


Wide Column



Graph Database

Persistencia Poliglota



Persistencia Políglota

Multi-model Databases

- Persistencia Poliglota → aumento significativo de la complejidad operativa
- Multi-model databases: soportan múltiples modelos de datos (document, key value, graph, etc)
 - Multi-model nativa:combinación de varios modelos de datos en un sistema
 - Multi-model no nativa: un modelo por vez.
 - Layered multi-model

Multi-model

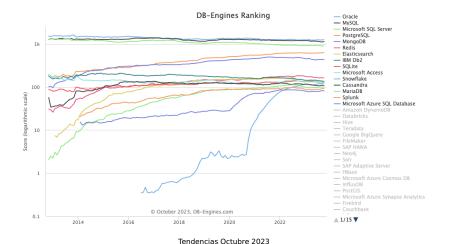
One back end, multiple data models

Ranking

415 systems in ranking, October 2023

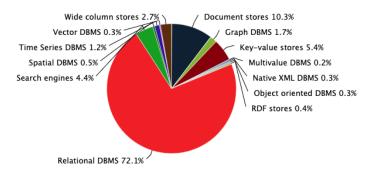
	Rank				Score		
Oct 2023	Sep 2023	Oct 2022	DBMS	Database Model	Oct 2023	Sep 2023	Oct 2022
1.	1.	1.	Oracle [Relational, Multi-model 🔞	1261.42	+20.54	+25.05
2.	2.	2.	MySQL 😷	Relational, Multi-model 👔	1133.32	+21.83	-72.06
3.	3.	3.	Microsoft SQL Server ☐	Relational, Multi-model 👔	896.88	-5.34	-27.80
4.	4.	4.	PostgreSQL #	Relational, Multi-model 👔	638.82	+18.06	+16.10
5.	5.	5.	MongoDB 🖽	Document, Multi-model 🔞	431.42	-8.00	-54.81
6.	6.	6.	Redis Telephone Telephone	Key-value, Multi-model 👔	162.96	-0.72	-20.41
7.	7.	7.	Elasticsearch	Search engine, Multi-model	137.15	-1.84	-13.92
8.	8.	8.	IBM Db2	Relational, Multi-model 👔	134.87	-1.85	-14.79
9.	9.	1 0.	SQLite #	Relational	125.14	-4.06	-12.66
10.	10.	4 9.	Microsoft Access	Relational	124.31	-4.25	-13.85
11.	11.	1 3.	Snowflake 🚹	Relational	123.24	+2.35	+16.51
12.	12.	4 11.	Cassandra 😷	Wide column, Multi-model 👔	108.82	-1.24	-9.12
13.	13.	4 12.	MariaDB 🚼	Relational, Multi-model 📆	99.66	-0.79	-9.65
14.	14.	14.	Splunk	Search engine	92.37	+0.98	-2.28
15.	15.	1 6.	Microsoft Azure SQL Database	Relational, Multi-model 👔	80.93	-1.80	-4.03
16.	16.	4 15.	Amazon DynamoDB 🖽	Multi-model 🛐	80.91	+0.00	-7.44
17.	17.	1 20.	Databricks	Multi-model 📆	75.82	+0.64	+18.21
18.	18.	4 17.	Hive	Relational	69.18	-2.65	-11.42
19.	19.	4 18.	Teradata	Relational, Multi-model 🛐	58.56	-1.77	-7.51
20.	20.	1 22.	Google BigQuery	Relational	56.57	+0.11	+4.12

Evolución de la Popularidad



Distribución por modelo

Ranking scores per category in percent, October 2023



NewSQL



NewSQL

 The End of an Architectural Era (It's Time for a Complete Rewrite). Stonebraker, Hachem, Helland.



- El fin de "one size fits all"
- Empezar de cero, abandonar el código legado.
- La arquitectura de los DBMS es esencialmente idéntica a la de System R.
- H-Store -> VoltDB

¹VLDB '07 Proceedings of the 33rd international conference on Very large data bases

NewSQL Definition

Definición 451 Group

A DBMS that delivers the scalability and flexibility promised by NoSQL while retaining the support for SQL queries and/or ACID, or to improve performance for appropriate workloads.

Stonebraker Definición

- SQL as the primary interface.
- ACID support for transactions
- Non-locking concurrency control.
- High per-node performance.
- Parallel, shared-nothing architecture.

Document Databases

Definición

Document Database

Es una base no-relacional que almacena los datos como documentos estructurados.

El concepto principal es el **documento**

- Las BD almacena y recupera documentos.
- Los documentos pueden ser XML, JSON, BSON, etc

Document Database

Es una base no-relacional que almacena los datos como documentos estructurados.

El concepto principal es el documento

- Las BD almacena y recupera documentos.
- Los documentos pueden ser XML, JSON, BSON, etc

Documento

Es una colección de pares: nombre de campo y valor. Los valores pueden ser un valor simple o una estructura compleja como listas, otro documento o listas de documentos hijos

Definición

Document Database

Es una base no-relacional que almacena los datos como documentos estructurados.

El concepto principal es el documento

- Las BD almacena y recupera documentos.
- Los documentos pueden ser XML, JSON, BSON, etc

Documento

Es una colección de pares: nombre de campo y valor. Los valores pueden ser un valor simple o una estructura compleja como listas, otro documento o listas de documentos hijos

Ejemplos

MongoDB, RavenDB, eXist, CouchDB, CouchBase, ArangoDB

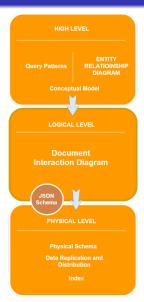
XML vs JSON

Colecciones

- ArangoDB, MongoDB agrupan documentos en colecciones.
 - No es necesario que tengan la misma estructura.
 - Decisión de diseño: ¿como agrupar documentos en colecciones?
- RavenDB
 - Una colección es una forma de hablar de todos los documentos que comparten una misma marca de tipo
 - Cuando se utiliza la API de .Net la marca de tipo se realiza automáticamente inferida del nombre de la clase del objeto que se guarda.
- RethinkDB
 - Los documentos se agrupan en "tablas"
 - Hay "streams" y "selections"
- CouchDB/CouchBase
 - Identificar tipo por un doc type.
 - CouchBase: Data Bucket(no es lo mismo que colecciones)

Metodología

Modelización



Consideraciones de Diseño

Desnormalización

```
{
order_item_ID : 834838,
   order_ID: 8827,
   quantity: 3,
   cost_per_unit: 8.50,
   product_ID: 3648
}
```

```
{
   product_ID: 3648,
   product_description: "1 package laser printer paper.
   100% recycled.",
   product_name: "Eco-friendly Printer Paper",
   product_category: "office supplies",
   list_price: 9.00
```

Desnormalización

```
f
order_item_ID : 834838,
  order_ID: 8827,
  quantity: 3,
  cost_per_unit: 8.50,
  product_ID: 3648
}

product_ID: 3648,
product_description: "1 package laser printer paper.
  100% recycled.",
product_name : "Eco-friendly Printer Paper",
product_category : "office supplies",
list_price : 9.00
}
```

Desnormalizacion

Desnormalización

```
f
order_item_ID : 834838,
  order_ID: 8827,
  quantity: 3,
  cost_per_unit: 8.50,
  product_ID: 3648
}

product_ID: 3648,
product_description: "1 package laser printer paper.
  100% recycled.",
product_name : "Eco-friendly Printer Paper",
product_category : "office supplies",
list_price : 9.00
}
```

Desnormalizacion

Desnormalización

```
product ID: 3648,
order_item_ID : 834838,
                                      product_description: "1 package laser printer paper.
   order ID: 8827.
                                        100% recycled.",
   quantity: 3,
                                      product name: "Eco-friendly Printer Paper",
   cost per unit: 8.50,
                                      product_category : "office supplies",
   product ID: 3648
                                      list_price : 9.00
                         Desnormalizacion
             order_item_ID : 834838,
                order ID: 8827,
                quantity: 3,
                cost_per_unit: 8.50,
                product :
                         product description: "1 package laser printer
                           paper, 100% recycled.",
```

product_name : "Eco-friendly Printer Paper",
product category : "office supplies",

list price: 9.00

Desnormalización

¿Cuanta desnormalización es demasiada?

- Generar facturas y remitos para los clientes (95 %)
- Generar reportes para la gerencia (5 %)

```
{
    order_item_ID: 834838,
    order_ID: 8827,
    quantity: 3,
    cost_per_unit: 8.50,
    product:
    {
        product_description: "1 package laser printer
        paper. 100% recycled.",
        product_name: "Eco-friendly Printer Paper",
        product_ategory: "office supplies",
        list_price: 9.00
    }
}
```

```
{
    product_description: "1 package laser printer paper.
    100% recycled.",
    product_name : "Eco-friendly Printer Paper",
    product_category : 'office supplies',
    list_price : 9.00
}
```

Desnormalización

¿Cuanta desnormalización es demasiada?

- Generar facturas y remitos para los clientes (95 %)
- Generar reportes para la gerencia (5 %)

```
{
  product_description: "1 package laser printer paper.
    100% recycled.",
  product_name: "Eco-friendly Printer Paper",
  product_category: 'office supplies',
  list_price: 9.00
}
```

```
{
    order_item_ID : 834838,
    order_ID: 8827,
    quantity: 3,
    cost_per_unit: 8.50,
    product_name : "Eco-friendly Printer Paper"
}
```

Diseño Físico

Documentos mutables

```
{
  truck_id: 'T87V12',
  time: '08:10:00',
  date : '27-May-2015',
  driver_name: 'Jane Washington',
  fuel_consumption_rate: '14.8 mpg',
  ...
}
```

Diseño Físico

Documentos mutables

```
{
  truck_id: 'T87V12',
  time: '08:10:00',
  date : '27-May-2015',
  driver_name: 'Jane Washington',
  fuel_consumption_rate: '14.8 mpg',
  ...
}
```

Diseño Físico

Documentos mutables

```
{
  truck_id: 'T87V12',
  time: '08:10:00',
  date : '27-May-2015',
  driver_name: 'Jane Washington',
  fuel_consumption_rate: '14.8 mpg',
  ...
}
```

```
truck id: 'T87V12',
date: '27-May-2015',
driver name: 'Jane Washington'.
operational_data:
              {time : '00:01',
               fuel_consumption_rate: '14.8 mpg',
               {time : '00:04',
               fuel_consumption_rate: '12.2 mpg',
               ...}.
               {time : '00:07',
               fuel_consumption_rate: '15.1 mpg',
               ...},
   Considerar el ciclo de vida
```

Modelo Conceptual -> DID -> Documentos

- DER Modelo conceptual de alto nivel.
- DID (Modelo/Diagrama de Interrelación de Documentos).
- JSON Schema: especificación de la estructura de los documentos.

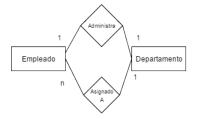
¿Cómo resolvemos la interrelación entre documentos?

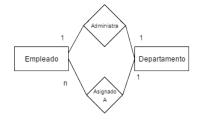
- DER Modelo conceptual de alto nivel.
- DID (Modelo/Diagrama de Interrelación de Documentos).
- JSON Schema: especificación de la estructura de los documentos.

¿Cómo resolvemos la interrelación entre documentos?

Incrustar o Referenciar

La decisión más importantes es si incrustar o referenciar, lo que determinará el grado de desnormalización de los documentos





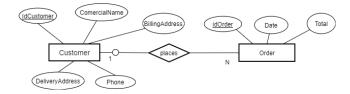
- Incrustar el departamento en el empleado
- Incrustar los empleados en el departamento
- Referenciar los empleados e incrustar el departamento en empleado.
- Referenciar de ambos lados
- Incrustar de ambos lados
- etc, etc...

¿Que es Referenciar?

En un documento se hace referencia a un ID o una lista de ID de otro documento

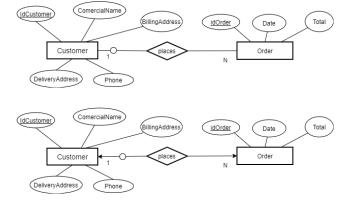
¿Que es Referenciar?

En un documento se hace referencia a un ID o una lista de ID de otro documento



¿Que es Referenciar?

En un documento se hace referencia a un ID o una lista de ID de otro documento

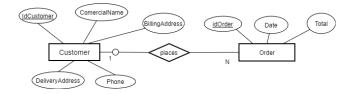


¿Que es Incrustar?

En un documento se incluyen todos los datos (en principio) de otro documento

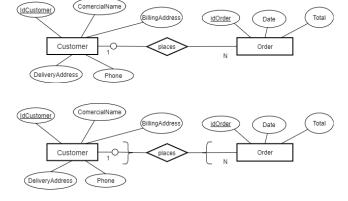
¿Que es Incrustar?

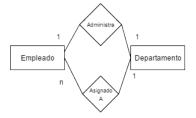
En un documento se incluyen todos los datos (en principio) de otro documento



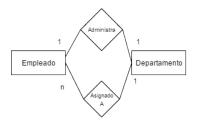
¿Que es Incrustar?

En un documento se incluyen todos los datos (en principio) de otro documento

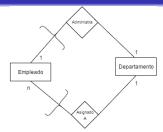




Modelo conceptual: DER

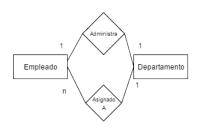


Modelo conceptual: DER



DID: Alternativa 1 Todo Incrustado en Depto

Se omiten los atributos por razones didácticas

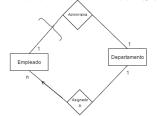


Modelo conceptual: DER

Administra

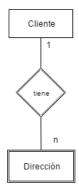
1
Departamento
1
Asignado
A

DID: Alternativa 1 Todo Incrustado en Depto

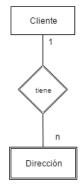


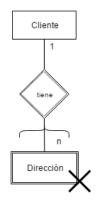
DID: Alternativa 2 - Incrustar sólo Gerente.

Entidades débiles

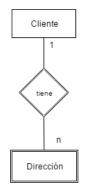


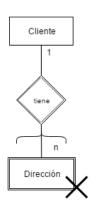
Entidades débiles





Entidades débiles



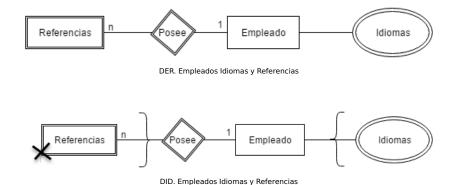


```
"cliente_id": 76123,
"nombre": "Acme Data Modeling
Services".
"tipo_de_cliente": "business",
"direcciones" :
    {calle: "San Martin 2222".
    ciudad: "Caseros",
    provincia: "Buenos Aires",
    codigo_postal: 99076} ,
    {calle: "9 de Julio 2223".
    ciudad: "CABA".
    codigo_postal: 01097}
```

Entidades Débiles - Atributos Multivaluados



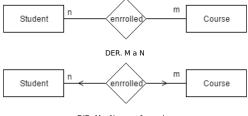
Entidades Débiles - Atributos Multivaluados



Cardinalidad M a N



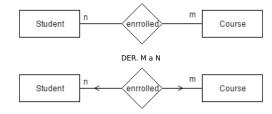
Cardinalidad M a N



DID. M a N con referencias

Cardinalidad M a N

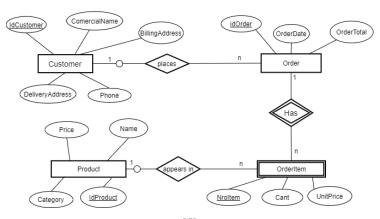
Se omiten los atributos por razones didácticas

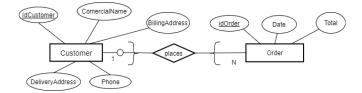


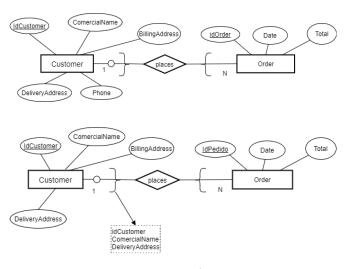
DID. M a N con referencias

```
{ courseID: 'C1667',
   title: 'Introduction to Anthropology',
   instructor: 'Dr. Margret Austin',
   credits: 3.
  enrolledStudents: ['S1837', 'S3737', 'S9825' ...
     'S1847'] },
{ courseID: 'C2873',
  title: 'Algorithms and Data Structures',
  instructor: 'Dr. Susan Johnson',
   credits: 3.
  enrolledStudents: ['S1837', 'S3737', 'S4321', 'S9825'
    ... 'S1847'] },
{ courseID: C3876,
  title: 'Macroeconomics',
  instructor: 'Dr. James Schulen',
   credits: 3,
   enrolledStudents: ['S1837', 'S4321', 'S1470', 'S9825'
     ... 'S1847'] },
```

Desnormalización parcial

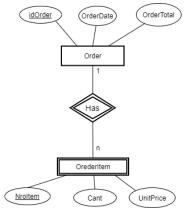






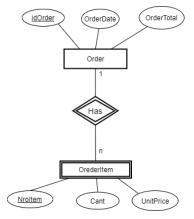
DID con desnormalización parcial

Desnormalización parcial

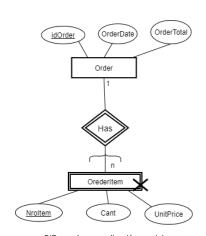


DID con desnormalización parcial

Desnormalización parcial

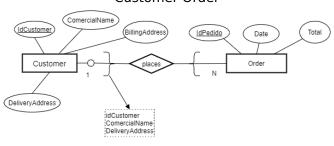


DID con desnormalización parcial

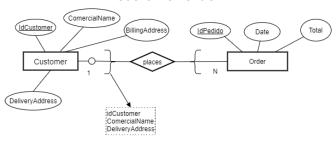


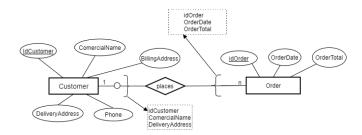
DID con desnormalización parcial

Customer-Order

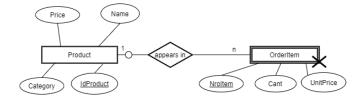


Customer-Order

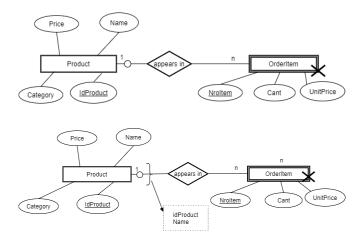




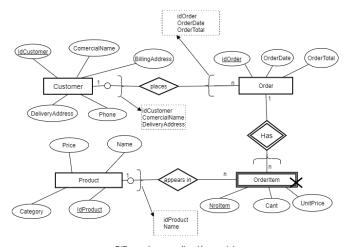
Producto-OrderItem



Producto-OrderItem



DID COMPLETO

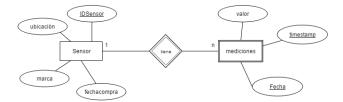


DID con desnormalización parcial

JSON Schema para Documento Orden

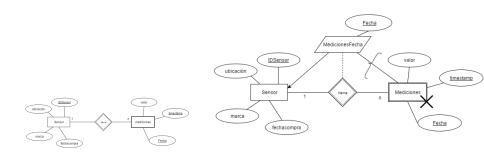
```
"Order": {"type": "object",
  "properties": {
     "idOrder": {"type":"integer" },
     "Date":{"type":"string", "format": "date-time"},
     "Total":{"type":"integer"},
     "Customer": {
           "type": "object",
           "properties":{
               "idCustomer":{"tvpe":"integer"}.
               "ComercialName":{"type":"string"},
               "DeliveryAddress":{"type":"string"}
     "OrderItem":{
          "type": "Array" ,
          "items":
            {"type": "object".
             "properties":{
                 "NroItem":{"type":"integer"},
                 "Cant":{"type":"integer"},
                 "UnitPrice":{" type ":" string " }.
                 "IdProduct":{"type":"integer" }.
                 "Name":{"type":"string" }}
```

Uso de Documentos Auxiliares



¿Que pasa cuando la cantidad de mediciones es muy grande y además se actualiza permanentemente?

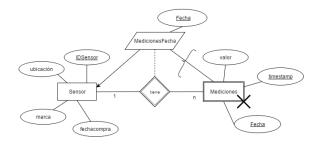
Uso de Documentos Auxiliares



Se necesita crear un tipo de documento auxiliar que permita particionar las mediciones

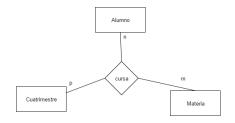
Uso de Documentos Auxiliares

JSON Schema



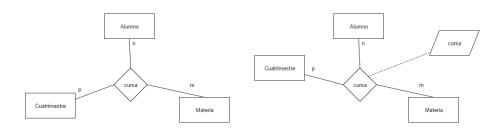
```
"MedicionesFecha": {"type": "object",
    "properties": {
    "IDSensor": {"type":"integer" },
    "Fecha":("type":"format":"date-time"},
    "Mediciones":{"type":"array",
    "items": {"type":"object",
    "properties":{"timestamp":{"type":"string","format":"date-time"},    "valor":"type":"decimal"}}}
}
}
```

Se omiten los atributos por razones didácticas



¿Como resolvemos la interrelación cursa?

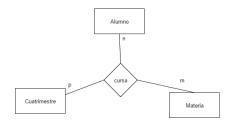
Se omiten los atributos por razones didácticas



Opción básica:

Se genera un documento con las claves de cada uno

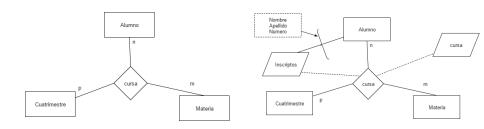
Se omiten los atributos por razones didácticas



Supongamos

Una consulta muy común es saber cuales son los alumnos anotados en una materia en un cuatrimestre

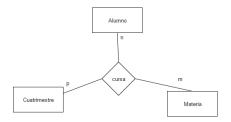
Se omiten los atributos por razones didácticas



Supongamos

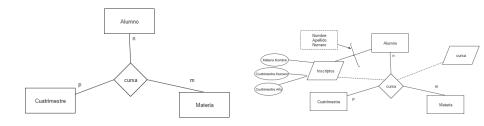
Una consulta muy común es saber cuales son los alumnos anotados en una materia en un cuatrimestre

Se omiten los atributos por razones didácticas

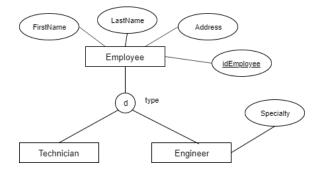


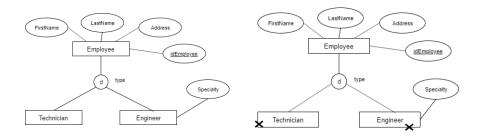
¿Y si queremos además el nombre de la materia y el numero y año del cuatrimestre?

Se omiten los atributos por razones didácticas



La propia semántica de la cardinalidad de la ternaria nos facilita este modelo





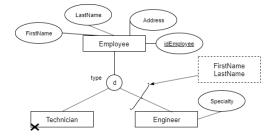
La facilidad de tener esquema flexible nos facilita el diseño. Podemos usar sólo un tipo de documentos para toda la jerarquía.

Supongamos que:

Queremos conservar la entidad *Engineer* como tipo de documento independiente porque una consulta importante es listar todos los ingenieros con sus datos.

Supongamos que:

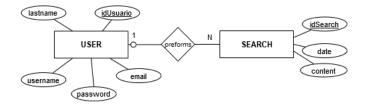
Queremos conservar la entidad *Engineer* como tipo de documento independiente porque una consulta importante es listar todos los ingenieros con sus datos.



Caso especial

Supongamos que:

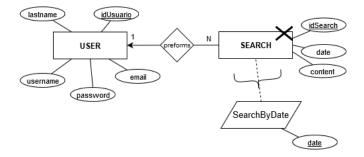
Un caso a considerar es cuando se hace necesario agrupar múltiples instancias de una entidad, por uno o más atributos, en un solo documento.



Caso especial

Supongamos que:

Un caso a considerar es cuando se hace necesario agrupar múltiples instancias de una entidad, por uno o más atributos, en un solo documento.



Bibliografía

- NoSQL for Mere Mortals Dan Sullivan
- NoSQL Distilled. A Brief Guide to the Emerging World of Polyglot Persistence - Pramod J. Sadalage y Martin Fowler
- A Big Data Modeling Methodology for NoSQL Document Databases . Database Systems Journal, Vol XI, 2020. ISSN 2069 - 3230. Gerardo Rossel, Andrea Manna
- Diseño de Bases de Datos Basadas en Documento:
 Modelo de Interrelación de Documentos Gerardo Rossel y Andrea Manna
- MongoDB Applied Design Patterns Rick Copeland
- CouchDB- The Definitive Guide J. Chris Anderson, Jan Lehnardt, Noah Slater
- RavenDB in Action Itamar Syn-Hershko

